

Université Libre de Bruxelles
Faculté des Sciences | Département d'Informatique

Rapport de Projet : Détection de communautés dans DBLP

Étudiant 1
Wilton Da Silva
Matricule : 000589652

Étudiant 2
Roberto Rabei
Matricule : 000593814

Année académique 2025-2026

Table des matières

1. Introduction	3
2. Méthodologie et Structures de Données	3
2.1. Tâche 1 : Co-publications (Graphe non-orienté)	3
2.1.1. Optimisation (Union-Find)	3
2.2. Tâche 2 : Relations fortes (Graphe orienté)	3
2.2.1. Approche Mixte : Online et Offline	3
2.2.2. Analyse des Composantes Fortement Connexes (Tarjan)	3
3. Résultats et Analyse	4
3.1. Statistiques du jeu de données	4
3.2. Comparaison des structures communautaires	4
3.3. Analyse des communautés orientées (Top 5)	4
3.4. Analyse géographique (Bonus)	5
4. Conclusion	5
5. Mentions relatives à l'IA	5

1. Introduction

Ce projet vise à analyser le réseau de co-publications scientifiques DBLP en extrayant des structures communautaires via deux approches algorithmiques : l'Union-Find pour les relations simples et l'algorithme de Tarjan pour les collaborations fortes.

2. Méthodologie et Structures de Données

2.1. Tâche 1 : Co-publications (Graphe non-orienté)

Pour cette tâche, nous devons identifier les composantes connexes dans un flux continu de données.

2.1.1. Optimisation (Union-Find)

Nous avons privilégié une structure **Union-Find** (Disjoint Set Union) plutôt qu'une liste d'adjacence pour deux raisons majeures :

- **Efficacité mémoire** : Un graphe complet pour une publication de k auteurs nécessite $\frac{k(k-1)}{2}$ arêtes. L'Union-Find ne nécessite que $k - 1$ opérations d'union, évitant la saturation de la RAM.
- **Traitement Online** : Contrairement à un BFS/DFS qui nécessite de reparcourir le graphe ($O(V + E)$) à chaque requête, l'Union-Find maintient les métriques (nombre de composantes, tailles) de manière active durant l'insertion. Les métriques globales sont donc accessibles en $O(1)$ à tout instant.

2.2. Tâche 2 : Relations fortes (Graphe orienté)

Ici, nous isolons les noyaux de collaboration stable en filtrant les arêtes et en utilisant un graphe orienté.

2.2.1. Approche Mixte : Online et Offline

1. **Phase Online** : Conformément à l'énoncé, nous comptabilisons uniquement les paires orientées du premier auteur vers ses co-auteurs ($A \rightarrow B$). Nous utilisons une table de hachage imbriquée `HashMap<Integer, HashMap<Integer, Integer>>`. Cette approche ciblée maintient une complexité spatiale par publication de $O(k)$ (où k est le nombre d'auteurs). Elle évite une explosion combinatoire en $O(k^2)$ qui saturerait la mémoire de la JVM (`OutOfMemoryError`) lors du traitement de publications massives (hyper-authorship).
2. **Phase Offline** : Une fois le parsing terminé, nous appliquons le seuil exigé en ne conservant que les arêtes de poids ≥ 6 . Lors de la construction de la liste d'adjacence finale, nous utilisons un ensemble `activeNodes` (Set) pour ne mémoriser que les auteurs ayant survécu à ce filtrage strict.

2.2.2. Analyse des Composantes Fortement Connexes (Tarjan)

Pour extraire ces noyaux, nous utilisons le concept de **CFC** : un sous-ensemble où chaque nœud peut atteindre tous les autres (réciprocité). Nous avons implémenté l'**algorithme de Tarjan**, optimal car il identifie toutes les CFC en un seul parcours DFS ($O(V + E)$) grâce aux concepts d'index de découverte et de `low-link`. Optimisation majeure : Pour garantir des performances optimales et un décompte exact, l'algorithme n'initie sa recherche que sur l'ensemble des `activeNodes`. Cela nous évite d'exécuter l'algorithme sur l'entièreté des 4 millions d'auteurs isolés de DBLP et fausser les statistiques. Enfin, chaque composante identifiée, y compris les auteurs de taille 1 ayant survécu au filtrage, est dûment comptabilisée.

3. Résultats et Analyse

3.1. Statistiques du jeu de données

- Nombre d'auteurs identifiés : 7 995 940
- Nombre de publications traitées : 4 031 750

3.2. Comparaison des structures communautaires




Fig. 1. – Comparaison des distributions : Tâche 1 (gauche) et Tâche 2 (droite).

La Tâche 1 est dominée par une composante géante due à la permissivité du lien. En revanche, la Tâche 2 fragmente le réseau en noyaux denses, illustrant la transition d'un réseau de « connaissance » vers un réseau de « collaboration stable ».

3.3. Analyse des communautés orientées (Top 5)


Nous avons calculé le diamètre des plus grandes CFC pour évaluer leur cohésion interne.

Rang	Taille	Diamètre
1	133	30
2	73	35
3	38	13
4	34	7
5	33	6

- **Modèle « Petit Monde » (Rang 5) :** Un diamètre très faible (6) pour 33 membres indique un noyau très dense, typique d'un laboratoire de recherche où les membres sont presque tous co-auteurs directs.
- **Modèle « Réseau étendu » (Rang 1) :** Un diamètre de 30 suggère une structure plus linéaire, comme une chaîne de collaborations successives s'étendant sur plusieurs institutions.

3.4. Analyse géographique (Bonus)

Répartition géographique - Communauté Rank 1



Répartition géographique - Communauté Rank 5




Fig. 2. – Distribution par pays pour les communautés de Rang 1 et Rang 5.

En enrichissant nos données via l'API **OpenAlex**, nous avons analysé l'origine des auteurs du Top 10. Les résultats montrent une forte corrélation entre la structure du graphe et la géographie : les noyaux les plus denses (diamètre faible) sont souvent localisés dans un même pays, tandis que les réseaux étendus (diamètre élevé) reflètent des collaborations transcontinentales.

4. Conclusion

Ce projet nous a permis de confronter les théories des graphes à une volumétrie réelle. La gestion du flux (Online) a imposé des choix de structures de données performantes (**HashMap**, **Union-Find**). L'analyse finale prouve que le filtrage par le poids des arêtes et la forte connexité sont des outils puissants pour extraire du sens d'un réseau social complexe.

5. Mentions relatives à l'IA

- **Aide à l'interprétation sémantique** : L'IA nous a aidés à faire le pont entre les métriques algorithmiques (diamètre, taille de CFC) et la réalité du monde académique.

Elle a permis de valider que nos « noyaux denses » correspondaient logiquement à des laboratoires spécialisés et nos « chaînes étendues » à des réseaux de collaborations interdisciplinaires ou historiques.

- **Structure du rapport** : La structure du rapport a été optimisée par l'IA pour garantir que nos explications s'intègrent parfaitement dans le cadre de la limite de pages.